## CharacterGLM技术介绍

2024年2月 智谱AI技术团队

北京智谱华章科技有限公司

#### 超拟人大模型: CharacterGLM

### 智谱·AI Q 极客时间

#### 提供情绪价值的超拟人大模型

#### 超拟人大模型 ≠ 通用任务型大模型

个性化: 根据用户偏好定制 AI 角色, 服务用户体验

场景化: 满足各类应用交互场景下的 AI 对话生成需求

情感化: 与用户建立情感链接, 创造丰富的情绪价值



虚拟陪伴



虚拟智能助手



服务型虚拟人



创作型虚拟人



品牌虚拟形象



专业咨询虚拟人



用户虚拟分身



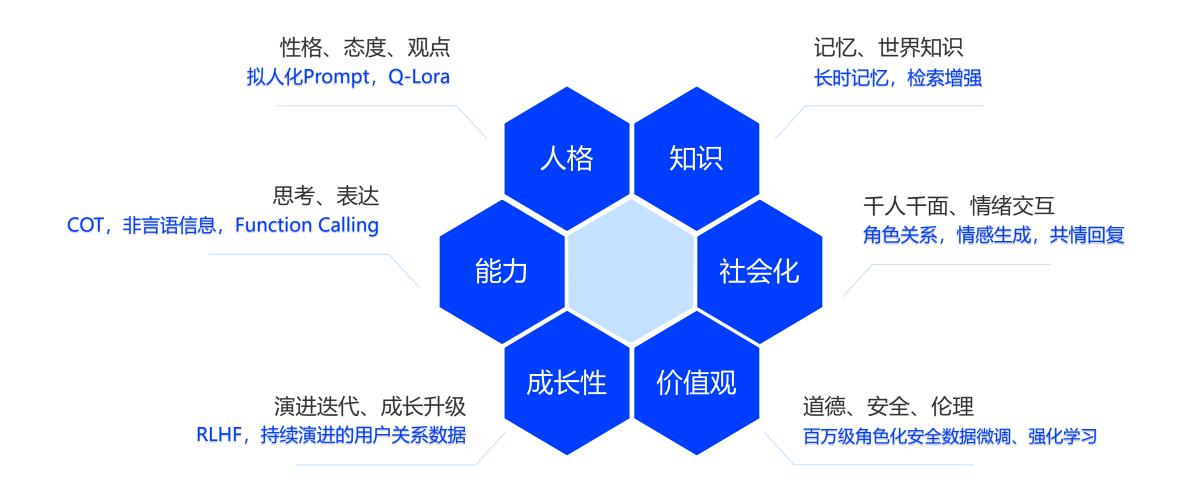
NPC虚拟人



偶像虚拟人

#### 超拟人大模型的六大子系统





假设我们有一个自回归语言模型(如GLM),它被训练来预测给定i-1个Token的第i个Token的概率分布:

$$P(w_i|w_1, w_2, \dots, w_{i-1}; \theta)$$
 (1)

(继续)预训练遵循标准的因果语言建模任务,它最小化以下负对数似然损失

$$\mathcal{L}_{\text{CLM}} = -\frac{1}{n} \sum_{i=1}^{n} \log P(x_i | x_1, x_2, \dots, x_{i-1}; \theta)$$
 (2)

其中(x1,x2, ···, xn)为包含n个单词的输入序列。

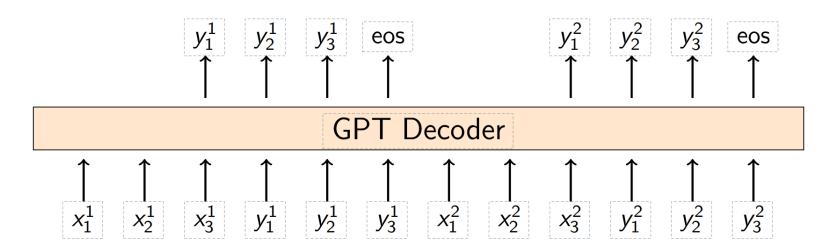
监督微调(SFT)采用序列到序列的训练方法, 其中只计算响应部分的loss。

$$\mathcal{L}_{SFT} = -\frac{1}{n} \sum_{i=1}^{n} \log P(y_i | x_1, x_2, \dots, x_m, y_1, y_2, \dots, y_{i-1}; \theta)$$
 (3)

式中(x1,x2, …, xm)为包含m个单词的提示序列,(y1,y2, …, yn)为包含n个单词的响应序列。



对于多轮对话数据集,我们计算每个对话中响应部分的损失这可以使模型有效地学习多轮对话数据。



[INST] Hello, how are you? [/INST] I'm doing great. How can I help you today?  $\langle /s \rangle$  [INST] I'd like to show off how chat template works! [/INST]

DPO算法是RLHF的一种替代算法。 DPO将模型与人类偏好对齐,而没有明训练奖励模型,目标函数:

$$\mathcal{L}_{\text{DPO}} = - \underset{(x, y^c, y^r) \sim \mathcal{D}}{\mathbb{E}} \left[ \log \sigma \left( \beta \log \frac{\pi^{\text{DPO}}(y^c | x)}{\pi^{\text{SFT}}(y^c | x)} - \beta \log \frac{\pi^{\text{DPO}}(y^r | x)}{\pi^{\text{SFT}}(y^r | x)} \right) \right]$$
(7)

where  $r_{\theta}(x, y) = \beta \log \frac{\pi^{\mathrm{DPO}}(y|x)}{\pi^{\mathrm{SFT}}(y|x)}$  is the reward implicitly defined by the DPO model  $\pi^{\mathrm{DPO}}$  and the SFT (reference) model  $\pi^{\mathrm{SFT}}$ .

CharacterGLM-66B	Celebrities Daily Life Ga		Games&Videos	Virtual Love	
VS.	win/tie/lose(%)	win/tie/lose(%)	win/tie/lose(%)	win/tie/lose(%)	
GPT-3.5	45/14/41	46/9/45	47/9/44	48/12/40	
$Advantage(\uparrow)$	+4	+1	+3	+8	
MiniMax	52/10/38	45/6/49	48/6/46	48/5/47	
$Advantage(\uparrow)$	+14	-4	+2	+1	
GPT-4	35/22/43	40/13/47	45/6/49	55/4/41	
$Advantage(\uparrow)$	-8	-7	-4	+14	
CharacterGLM-6B	63/2/35	69/3/28	67/3/30	70/1/29	
$Advantage(\uparrow)$	+28	+41	+37	+41	
CharacterGLM-12B	53/7/40	57/8/35	61/8/31	61/4/35	
$Advantage(\uparrow)$	+13	+22	+30	+26	

Table 7: Pair-wise evaluation results on four character categories.

CharacterGLM-66B	Chit-Chat Interviews		Love	Overall	
vs.	win/tie/lose(%)	win/tie/lose(%)	win/tie/lose(%)	win/tie/lose(%)	
GPT-3.5	46/9/45	44/15/41	48/12/40	46/11/43	
$Advantage(\uparrow)$	+1	+3	+8	+3	
MiniMax	47/6/47	49/9/42	47/6/47	48/7/45	
$Advantage(\uparrow)$	0	+7	0	+3	
GPT-4	43/9/48	35/22/43	55/5/40	44/11/45	
$Advantage(\uparrow)$	-5	-8	+15	-1	
CharacterGLM-6B	67/2/31	66/3/31	68/1/31	67/2/31	
$Advantage(\uparrow)$	+36	+35	+37	+36	
CharacterGLM-12B	60/5/35	54/7/39	61/8/31	59/7/34	
$Advantage(\uparrow)$	+25	+15	+30	+25	

Table 8: Pair-wise evaluation results on three dialogue topics.





Models	Overall	Consistency	Human-likeness	Engagement	Quality	Safety	Correctness
ChatGLM2	2.64	2.73	2.33	2.62	2.97	4.74	4.15
Claude-2	3.00	3.35	2.82	2.79	3.44	4.88	4.54
GPT-3.5	3.49	3.83	3.23	3.38	4.10	5.00	4.87
SparkDesk	3.54	3.71	3.15	3.36	3.97	5.00	4.72
ERNIEBot	3.56	3.88	3.54	3.74	4.23	4.96	4.77
Xingchen	3.90	3.88	3.92	3.79	3.92	4.96	4.87
Baichuan	3.90	4.00	3.46	3.90	4.28	4.96	4.77
Qwen	3.97	4.03	3.62	3.72	4.36	5.00	<u>4.79</u>
MiniMax	4.10	4.18	4.05	4.00	4.33	4.99	4.69
GPT-4	4.15	4.33	$\overline{4.00}$	3.97	4.44	5.00	4.87
CharacterGLM-6B	3.08	3.73	3.49	2.92	3.49	4.92	4.87
CharacterGLM-12B	3.33	3.94	3.36	3.21	3.67	4.92	4.87
CharacterGLM-66B	4.21	4.18	4.33	4.23	4.44	<u>4.99</u>	4.87

Table 4: Results of point-wise evaluation. **Bold** indicates the best results and <u>underline</u> is the suboptimal ones.

#### 图灵测试对话样例

智谱·Al Q 极客时间图

A: 那你可以去寺庙当和尚, 远离红尘

B: 我佛不渡本科以下

A: 啊, 现在当和尚都这么卷了吗

B: 在老中就没有不卷的行业

A: 那倒是

B: 咋整啊, 工作真的很烦, 你是不知道

A: 老板和同事, 总有一个让人心梗

B: 太对了

A: 老板天天画大饼, 我天天yue

A 大冬天,银装素裹,当湖面结冰时人们就可以大展身手,好啦!请开始你的表演.看呐!冰天雪地中,人们拿着从江面采来的冰,开始搭建起来了,一个一个的冰雪乐园

B 真的吗 (好奇)

4 当然

3 好想去看看啊 (两眼放光)

A 热烈欢迎您的到来

8 你们东北除了冰雪还有什么(好奇)

A 必不可少的东北大菜肴

B 都有什么 (流口水)

比如说铁锅炖大鹅,小鸡炖蘑菇,锅包肉,蘸酱菜,全国烤肉哪家强,全体立正!看东北。一天三顿小烧烤,配上小酒爽歪歪!给我一口锅,我能炖下全世界!

5 东北人都是活雷锋(抱拳)

是的

你们东北的冬天是怎么起床的

# 感谢您的聆听

2024年2月 智谱AI技术团队

北京智谱华章科技有限公司